

Riesgos modernos en calidad del software

Ley de Goodhart e IA: Gaming, Auditoría, Controles y Responsabilidad

CALLE TERRAZAS EDWIN

FERNANDEZ GUZMAN HELDER OCTAVIO

LUNA MAMANI EFRAIN FERNANDO

PEINADO PEREIRA JUAN CARLOS

VILLAZON VALDEZ JOSE PABLO

Marzo - 2026

Doctorado en Ciencias de la Computación

Calidad del Software con IA — 2026


¿Por qué este tema es relevante ahora?

- Expansión de sistemas de IA generativa y predictiva en sectores críticos (finanzas, salud, educación y sector público).
- Uso intensivo de métricas como *proxies* de calidad y seguridad.
- Cuando una métrica se convierte en objetivo, deja de ser una buena medida (Ley de Goodhart).

Este fenómeno se manifiesta hoy como:

- optimización estratégica de indicadores
- sobreajuste a benchmarks
- pérdida de alineación con el valor real

Efecto Goodhart en sistemas de IA



Ley de Goodhart: cuando una métrica se convierte en objetivo, deja de ser una buena medida.

- **Metric gaming** Optimización de indicadores sin mejora real del sistema.
- **Benchmark overfitting** Modelos optimizados para datasets o pruebas públicas.
- **Limitaciones de auditoría** Dificultad para evaluar sistemas complejos y opacos.
- **Responsabilidad algorítmica** Ambigüedad sobre quién responde por decisiones del sistema.

Pregunta guía y tesis

Pregunta de investigación

¿Cómo impacta la Ley de Goodhart en sistemas de software basados en IA y qué mecanismos de auditoría, control y responsabilidad permiten mitigar el *gaming* de métricas sin degradar la calidad del sistema?

Tesis

En sistemas basados en IA, la optimización intensiva de métricas formalizadas activa la Ley de Goodhart: cuando una medida se convierte en objetivo, deja de ser una buena medida.

Esto incentiva comportamientos de *gaming*, desplaza la calidad sustantiva y genera riesgos técnicos y éticos, lo que requiere rediseñar los marcos de QA hacia modelos auditables, multicriterio y con responsabilidad explícita.

Método de revisión

Estrategia de búsqueda

- Revisión narrativa estructurada de literatura académica, técnica y documentos regulatorios.
- Búsqueda en bases como Scopus, Google Scholar, arXiv y documentos institucionales.

Criterios de inclusión

- Publicaciones académicas recientes sobre riesgos en sistemas de IA
- Documentos regulatorios y marcos de gobernanza de IA
- Literatura sobre métricas, evaluación y auditoría algorítmica

Resultado

- Identificación de cinco patrones principales en la literatura
- Síntesis en cinco hallazgos estructurales (H1–H5)

ID	Hallazgo principal
H1	Gaming de métricas y benchmarks en IA
H2	Limitaciones de auditorías <i>black-box</i>
H3	Déficit de estándares de auditoría de IA
H4	Métricas responsables a lo largo del ciclo de vida
H5	Riesgos técnicos y legales derivados del gaming

Estos hallazgos sintetizan los principales patrones identificados en la literatura reciente.

H1 — Gaming de benchmarks

- La optimización de métricas puede producir mejoras aparentes sin mejorar el sistema real.
- Modelos optimizados para benchmarks específicos pueden distorsionar la evaluación del desempeño.
- Este fenómeno refleja la dinámica descrita por la Ley de Goodhart.

H2 — Limitaciones de auditorías *black-box*

- Auditorías externas sin acceso al modelo detectan solo parte de los riesgos.
- Algunos comportamientos adversariales permanecen ocultos.
- Esto limita la verificación independiente de sistemas de IA.

H3 — Déficit de estándares para auditoría de IA

- El ecosistema de auditoría de IA aún se encuentra fragmentado.
- Existen iniciativas regulatorias y marcos de referencia, pero no estándares consolidados ampliamente adoptados.
- Esto genera heterogeneidad en los procesos de evaluación.

H4 — Métricas responsables

- La evaluación no debe limitarse al rendimiento del modelo.
- Debe considerar el ciclo de vida completo del sistema:
 - datos
 - entrenamiento
 - evaluación
 - despliegue

Riesgos técnicos y legales del *gaming* de métricas

- La combinación de optimización estratégica de métricas y opacidad algorítmica genera riesgos significativos.
- Estos riesgos no son únicamente técnicos, sino también regulatorios e institucionales.
- La dificultad para auditar sistemas complejos complica la asignación de responsabilidad.

Implicación

- Los marcos de QA para sistemas de IA deben incorporar auditoría, transparencia y responsabilidad.

Top 5: prácticas y anti-patrones

3 ideas prácticas para adoptar

- ✓ **Diversificar y rotar benchmarks**
Evitar dependencia de un único conjunto de evaluación.
- ✓ **Auditorías híbridas**
Combinar evaluaciones *black-box* y *white-box*.
- ✓ **Métricas de proceso**
Evaluar datos, entrenamiento, evaluación y despliegue.

2 anti-patrones a evitar

- ▲ **Benchmark washing**
Publicar únicamente los mejores resultados.
- ▲ **Compliance theater**
Auditorías formales sin evaluación real del sistema.

Conclusión

- La evaluación de sistemas de IA depende cada vez más de métricas y benchmarks.
- Cuando estas métricas se convierten en objetivos, emerge el fenómeno descrito por la Ley de Goodhart.
- Esto puede generar *gaming* de indicadores, evaluaciones distorsionadas y limitaciones de auditoría.
- En consecuencia, la calidad en sistemas de IA deja de ser únicamente una propiedad técnica y pasa a ser una propiedad **socio-técnica**.
- Los marcos de QA deben evolucionar hacia enfoques:
 - multicriterio
 - auditables
 - con responsabilidad explícita

Matriz de evidencia

ID	Fuente	Tipo	Hallazgo
S1	Goodhart (1975)	Fundacional	H1
S2	Singh et al. (2025)	Estudio empírico	H1
S3	Casper et al. (2024)	Académico	H2
S4	Costanza-Chock (2023)	Académico	H3
S5	Xia et al. (2023)	Académico	H4
S6	Kolt et al. (2026)	Legal / Académico	H5
S7	EU AI Act (2021)	Regulación	H3,H5
S8	NIST AI RMF (2023)	Marco industrial	H2,H3
S9	OECD AI Principles (2023)	Marco institucional	H4
S10	Strathern (1997)	Académico	H1
S11	Murphy (2021)	Libro académico	H1
S12	Doshi-Velez & Kim (2017)	Académico	H2